

Section 4. 손실 함수 심화 (Loss Function)

목차

- 섹션 0. 강의 소개
- 섹션 1. PyTorch 환경 설정
- 섹션 2. 딥러닝이란?
- 섹션 3. 손실 함수 (Loss Function)
- 섹션 4. 손실 함수에 대한 심화 이론 (Advanced Topics on Loss Function)
- 섹션 5. 경사 하강 (Gradient Descent)
- 섹션 6. 경사 하강에 대한 심화 이론 (Advanced Topics on Gradient Descent)

Objective

학습 목표

- One-hot-encoding에 대한 이해
- Entropy 개념에 대한 이해
- Cross Entropy Loss
- KL Divergence Loss



4-1. One-hot-encoding

One Hot Encoding

One Hot Encoding

- Categorical (범주형) 데이터를 처리하는데 사용되는 Encoding 방법
- 예를 들어서 동물의 종류 (3가지)에 대한 데이터:
 - “고양이”, “개”, “원숭이”
- 이것을 **One-hot-encoding**하면

“고양이”: [1, 0, 0]

“개”: [0, 1, 0]


“원숭이”: [0, 0, 1]

One Hot Encoding

One Hot Encoding

- Categorical (범주형) 데이터를 처리하는데 사용되는 Encoding 방법
- 이것을 **One-hot-encoding**하면
 - “고양이”: [1, 0, 0]
 - “개”: [0, 1, 0]
 - “원숭이”: [0, 0, 1]
- 범주형 데이터를 **Vector로 변환**하는 기법!

One Hot Encoding




index $c = c'$ 이면,

$$y_{c=c'} = 1$$

index $c \neq c'$ 이면

$$y_{c \neq c'} = 0$$

One Hot Encoding



4-2. Entropy

Entropy

열역학 (Thermodynamics) 에서의 **Entropy**

물리 시스템의 **무질서한 정도**.

정보 이론 (Information Theory) 에서의 **Entropy**

확률 분포의 **불확실성**의 정도.

Entropy

정보 이론 (Information Theory) 에서의 **Entropy**

확률 분포의 **불확실성**의 정도.

예를 들어,

- 내일 해가 뜰 확률은? $\rightarrow p_{sun} = 0.99999999...$
- 사실상 1이다.
- 해가 뜨는 것에 대한 Entropy 낮음!

Entropy

Entropy

$$\sum_i -p_i \log p_i$$

- 예시: **Binary Label** (즉, $i \in \{0,1\}$)
- p = 데이터 샘플이 **Label**을 가질 확률에 대한 **모델의 예측값**.
- $1 - p$ = **Label**을 가지지 않을 확률에 대한 예측값.

Entropy

Entropy

$$\sum_i -p_i \log p_i = -p \log p - (1-p) \log(1-p)$$

- 예시: **Binary Label** (즉, $i \in \{0,1\}$)
- p = 데이터 샘플이 **Label**을 가질 확률에 대한 모델의 예측값.
- $1 - p$ = **Label**을 가지지 않을 확률에 대한 예측값.

Entropy

$$0 \leq p < 0.5$$

- p 가 커지면서 Entropy도 증가

$$0.5 \leq p \leq 1$$


- p 가 커지면서 Entropy는 감소

$$p = 0.5$$

- Entropy가 최대치

$$\sum_i -p_i \log p_i$$

$$= -p \log p - (1 - p) \log(1 - p)$$



Entropy

$p = 0$

- Label을 가지지 않는 것에 확신
- 불확실함 최소 → Entropy 최소

$p = 1$


- Label을 가지는 것에 확신
- 불확실함 최소 → Entropy 최소

$p = 0.5$

- Label을 가질 확률을 완전히 Random
- 불확실함 최대 → Entropy 최대

$$\sum_i -p_i \log p_i$$

$$= -p \log p - (1 - p) \log(1 - p)$$



1. One-hot-encoding

2. Entropy

ACADENTIAL

4-3. Cross Entropy Loss

Cross Entropy Loss

- **L1 Loss (MAE Loss)**

$$\sum_{c=1}^C |Y_{i,c} - \hat{Y}_{i,c}|$$

- **Cross Entropy Loss**

$$\sum_{c=1}^C -Y_{i,c} \log \hat{Y}_{i,c}$$

- **Kullback-Leibler Divergence Loss (KL Divergence)**

$$\sum_{c=1}^C Y_{i,c} \cdot \log \left(\frac{Y_{i,c}}{\hat{Y}_{i,c}} \right)$$

Cross Entropy Loss

- Cross Entropy Loss (CE Loss)

$$\sum_{c=1}^C - Y_{i,c} \log \hat{Y}_{i,c}$$

Hard Label & Ground Truth class label가 c' 로 가정



$c \neq c'$ 의 경우

$$- Y_{i,c} \log \hat{Y}_{i,c}$$

$c = c'$ 의 경우

$$- Y_{i,c} \log \hat{Y}_{i,c}$$

Cross Entropy Loss

- Cross Entropy Loss (CE Loss)

$$\sum_{c=1}^C -Y_{i,c} \log \hat{Y}_{i,c}$$

Ground Truth class label가 c' 로 가정

$c \neq c'$ 의 경우

$$-\cancel{Y_{i,c}} \log \hat{Y}_{i,c} = 0$$

$c = c'$ 의 경우

$$-Y_{i,c} \log \hat{Y}_{i,c}$$

Cross Entropy Loss

- Cross Entropy Loss (CE Loss)

$$\sum_{c=1}^C -Y_{i,c} \log \hat{Y}_{i,c}$$



Ground Truth class label가 c' 로 가정

$c \neq c'$ 의 경우

$$-\cancel{Y_{i,c}} \log \hat{Y}_{i,c} = 0$$

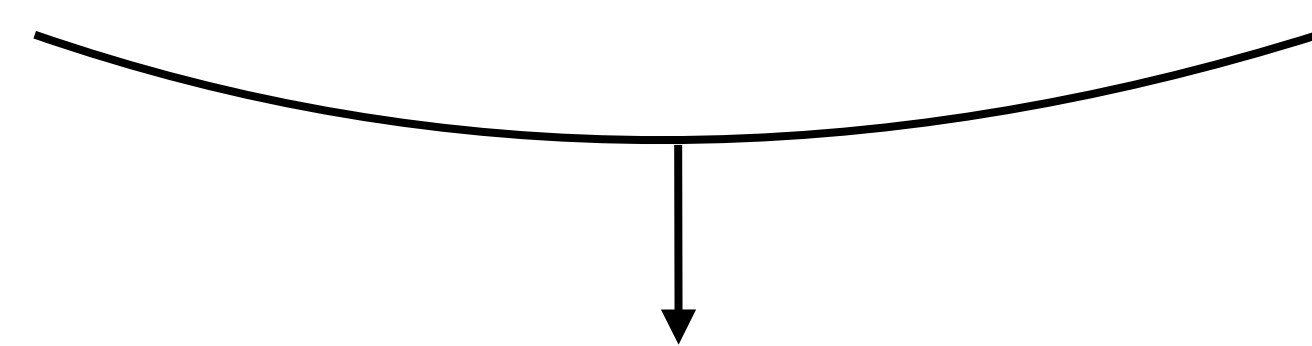
$c = c'$ 의 경우


$$-\cancel{Y_{i,c}} \log \hat{Y}_{i,c} \geq 0$$

≤ 0

Cross Entropy Loss

- Cross Entropy Loss (CE Loss)

$$\sum_{c=1}^C -Y_{i,c} \log \hat{Y}_{i,c}$$


$$-Y_{i,c=c'} \log(\hat{Y}_{i,c=c'})$$


$$-\log(\hat{Y}_{i,c=c'})$$

$c \neq c'$ 의 경우

$$-\cancel{Y_{i,c}} \overset{=0}{\log(\hat{Y}_{i,c})} = 0$$

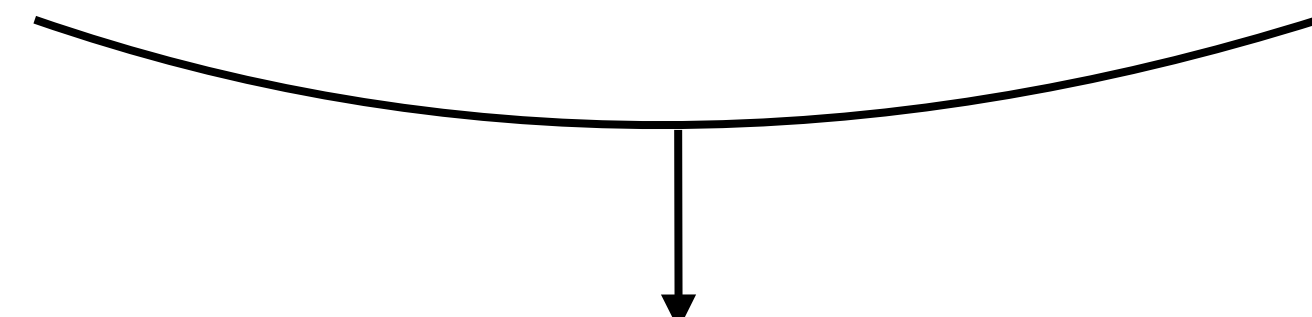

$c = c'$ 의 경우

$$-\cancel{Y_{i,c}} \overset{=1}{\log(\hat{Y}_{i,c})} \geq 0$$

≤ 0

Cross Entropy Loss

- Cross Entropy Loss (CE Loss)

$$\sum_{c=1}^C -Y_{i,c} \log \hat{Y}_{i,c}$$

$$-Y_{i,c=c'} \log(\hat{Y}_{i,c=c'})$$


$$-\log(\hat{Y}_{i,c=c'})$$

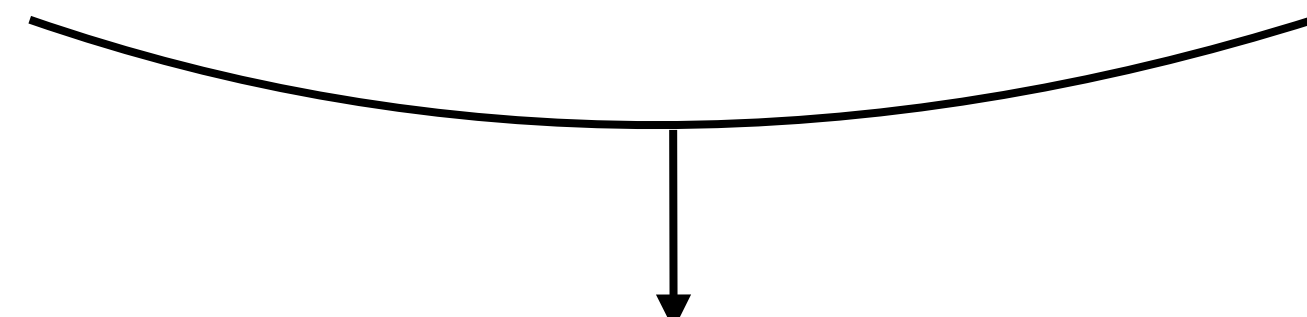

Ground Truth Label c' 일때,

$\hat{Y}_{i,c=c'}$ 가 높을수록 CE Loss가 낮아짐.

$\hat{Y}_{i,c=c'}$ 가 낮을수록 CE Loss가 높아짐.

Cross Entropy Loss

- Cross Entropy Loss (CE Loss)

$$\sum_{c=1}^C -Y_{i,c} \log \hat{Y}_{i,c}$$

$$-Y_{i,c=c'} \log(\hat{Y}_{i,c=c'})$$


$$-\log(\hat{Y}_{i,c=c'})$$



Ground Truth Label c' 일때,

$\hat{Y}_{i,c=c'}$ 가 높을수록 (잘 맞춘 것) CE Loss가 낮아짐.

$\hat{Y}_{i,c=c'}$ 가 낮을수록 (못 맞춘 것) CE Loss가 높아짐.

4-4. Kullback-Leibler Divergence Loss

Kullback-Leibler Divergence Loss

- **L1 Loss (MAE Loss)**

$$\sum_{c=1}^C |Y_{i,c} - \hat{Y}_{i,c}|$$

- **Cross Entropy Loss**

$$\sum_{c=1}^C -Y_{i,c} \log \hat{Y}_{i,c}$$

- **Kullback-Leibler Divergence Loss (KL Divergence)**

$$\sum_{c=1}^C Y_{i,c} \cdot \log \left(\frac{Y_{i,c}}{\hat{Y}_{i,c}} \right)$$

Kullback-Leibler Divergence Loss

Copyright©2023. Acadential. All rights reserved.

- **Kullback-Leibler Divergence Loss (KL Divergence)**

$$\sum_{c=1}^C Y_{i,c} \cdot \log \left(\frac{Y_{i,c}}{\hat{Y}_{i,c}} \right) = \sum_{c=1}^C Y_{i,c} \log Y_{i,c} - Y_{i,c} \log \hat{Y}_{i,c}$$

Kullback-Leibler Divergence Loss

- Kullback-Leibler Divergence Loss (KL Divergence)

$$\sum_{c=1}^C Y_{i,c} \cdot \log \left(\frac{Y_{i,c}}{\hat{Y}_{i,c}} \right) = \sum_{c=1}^C \boxed{Y_{i,c} \log Y_{i,c}} - Y_{i,c} \log \hat{Y}_{i,c}$$

Negative Entropy of $Y_{i,c}$

Entropy

$$\sum_i -p_i \log p_i$$

Kullback-Leibler Divergence Loss

- Kullback-Leibler Divergence Loss (KL Divergence)

$$\sum_{c=1}^C Y_{i,c} \cdot \log \left(\frac{Y_{i,c}}{\hat{Y}_{i,c}} \right) = \sum_{c=1}^C \underbrace{Y_{i,c} \log Y_{i,c}}_{\text{Negative Entropy of } Y_{i,c}} - \underbrace{Y_{i,c} \log \hat{Y}_{i,c}}_{\text{Cross Entropy Term}}$$

Cross Entropy Loss

$$\sum_{c=1}^C -Y_{i,c} \log \hat{Y}_{i,c}$$

Kullback-Leibler Divergence Loss

- Kullback-Leibler Divergence Loss (KL Divergence)

$$\sum_{c=1}^C Y_{i,c} \cdot \log \left(\frac{Y_{i,c}}{\hat{Y}_{i,c}} \right) = \sum_{c=1}^C \underbrace{Y_{i,c} \log Y_{i,c}}_{\text{Negative Entropy of } Y_{i,c}} - \underbrace{Y_{i,c} \log \hat{Y}_{i,c}}_{\text{Cross Entropy Term}}$$

Negative Entropy

$$\sum_c Y_{i,c} \log Y_{i,c}$$

Cross Entropy Loss

$$\sum_{c=1}^C -Y_{i,c} \log \hat{Y}_{i,c}$$

Kullback-Leibler Divergence Loss

- Kullback-Leibler Divergence Loss (KL Divergence)

$$\sum_{c=1}^C Y_{i,c} \cdot \log \left(\frac{Y_{i,c}}{\hat{Y}_{i,c}} \right) = \sum_{c=1}^C \underbrace{Y_{i,c} \log Y_{i,c}}_{\text{Negative Entropy of } Y_{i,c}} - \underbrace{Y_{i,c} \log \hat{Y}_{i,c}}_{\text{Cross Entropy Term}}$$



Negative Entropy

$$\sum_c Y_{i,c} \log Y_{i,c}$$

Cross Entropy Loss

$$\sum_{c=1}^C -Y_{i,c} \log \hat{Y}_{i,c}$$

$\hat{Y}_{i,c} \rightarrow Y_{i,c}$ 이면 Entropy가 된다!

KL Divergence의 해석

- Kullback-Leibler Divergence Loss (KL Divergence)

Negative Entropy of $Y_{i,c}$

$$\sum_{c=1}^C Y_{i,c} \cdot \log \left(\frac{Y_{i,c}}{\hat{Y}_{i,c}} \right) = \sum_{c=1}^C \boxed{Y_{i,c} \log Y_{i,c}} - Y_{i,c} \log \hat{Y}_{i,c}$$



- Negative Entropy가 높다 → 해당 샘플의 Label에 대해서 더 확신.
- 해당 샘플에 대해서는 더 잘 맞춰야함.
- 따라서, 더 높은 Loss를 주는 셈.

KL Divergence의 해석

- Kullback-Leibler Divergence Loss (KL Divergence)

$$\sum_{c=1}^C Y_{i,c} \cdot \log \left(\frac{Y_{i,c}}{\hat{Y}_{i,c}} \right) = \sum_{c=1}^C \boxed{Y_{i,c} \log Y_{i,c}} - Y_{i,c} \log \hat{Y}_{i,c}$$

Negative Entropy of $Y_{i,c}$

그런데 만약 Label이 **Soft label**이 아닌 **Hard label**일 경우?

KL Divergence의 해석

Hard Label $Y_{i,c} \in \{0,1\}$

$$\text{Entropy} = \sum_c -Y_{i,c} \log Y_{i,c} = 0$$

$$\begin{aligned} \text{KL Div. Loss} &= \sum_{c=1}^C Y_{i,c} \log Y_{i,c} - Y_{i,c} \log \hat{Y}_{i,c} \\ &= \sum_c -Y_{i,c} \log \hat{Y}_{i,c} = \text{CE Loss} \end{aligned}$$

Note: A red arrow points from the term $Y_{i,c} \log Y_{i,c}$ in the first line to the red text "= 0" above the second line, indicating its simplification.

Soft Label vs. Hard Label

Output

$$y_0 = 0$$


...

$$y_{c'} = 1$$

...

$$y_{C-1} = 0$$

Hard Label



KL Divergence Loss

=

Cross Entropy Loss

Output

$$y_0 = 0$$

...

$$y_{c'} = 0.8$$

$$y_{c''} = 0.2$$

...

$$y_{C-1} = 0$$

Soft Label

KL Divergence Loss

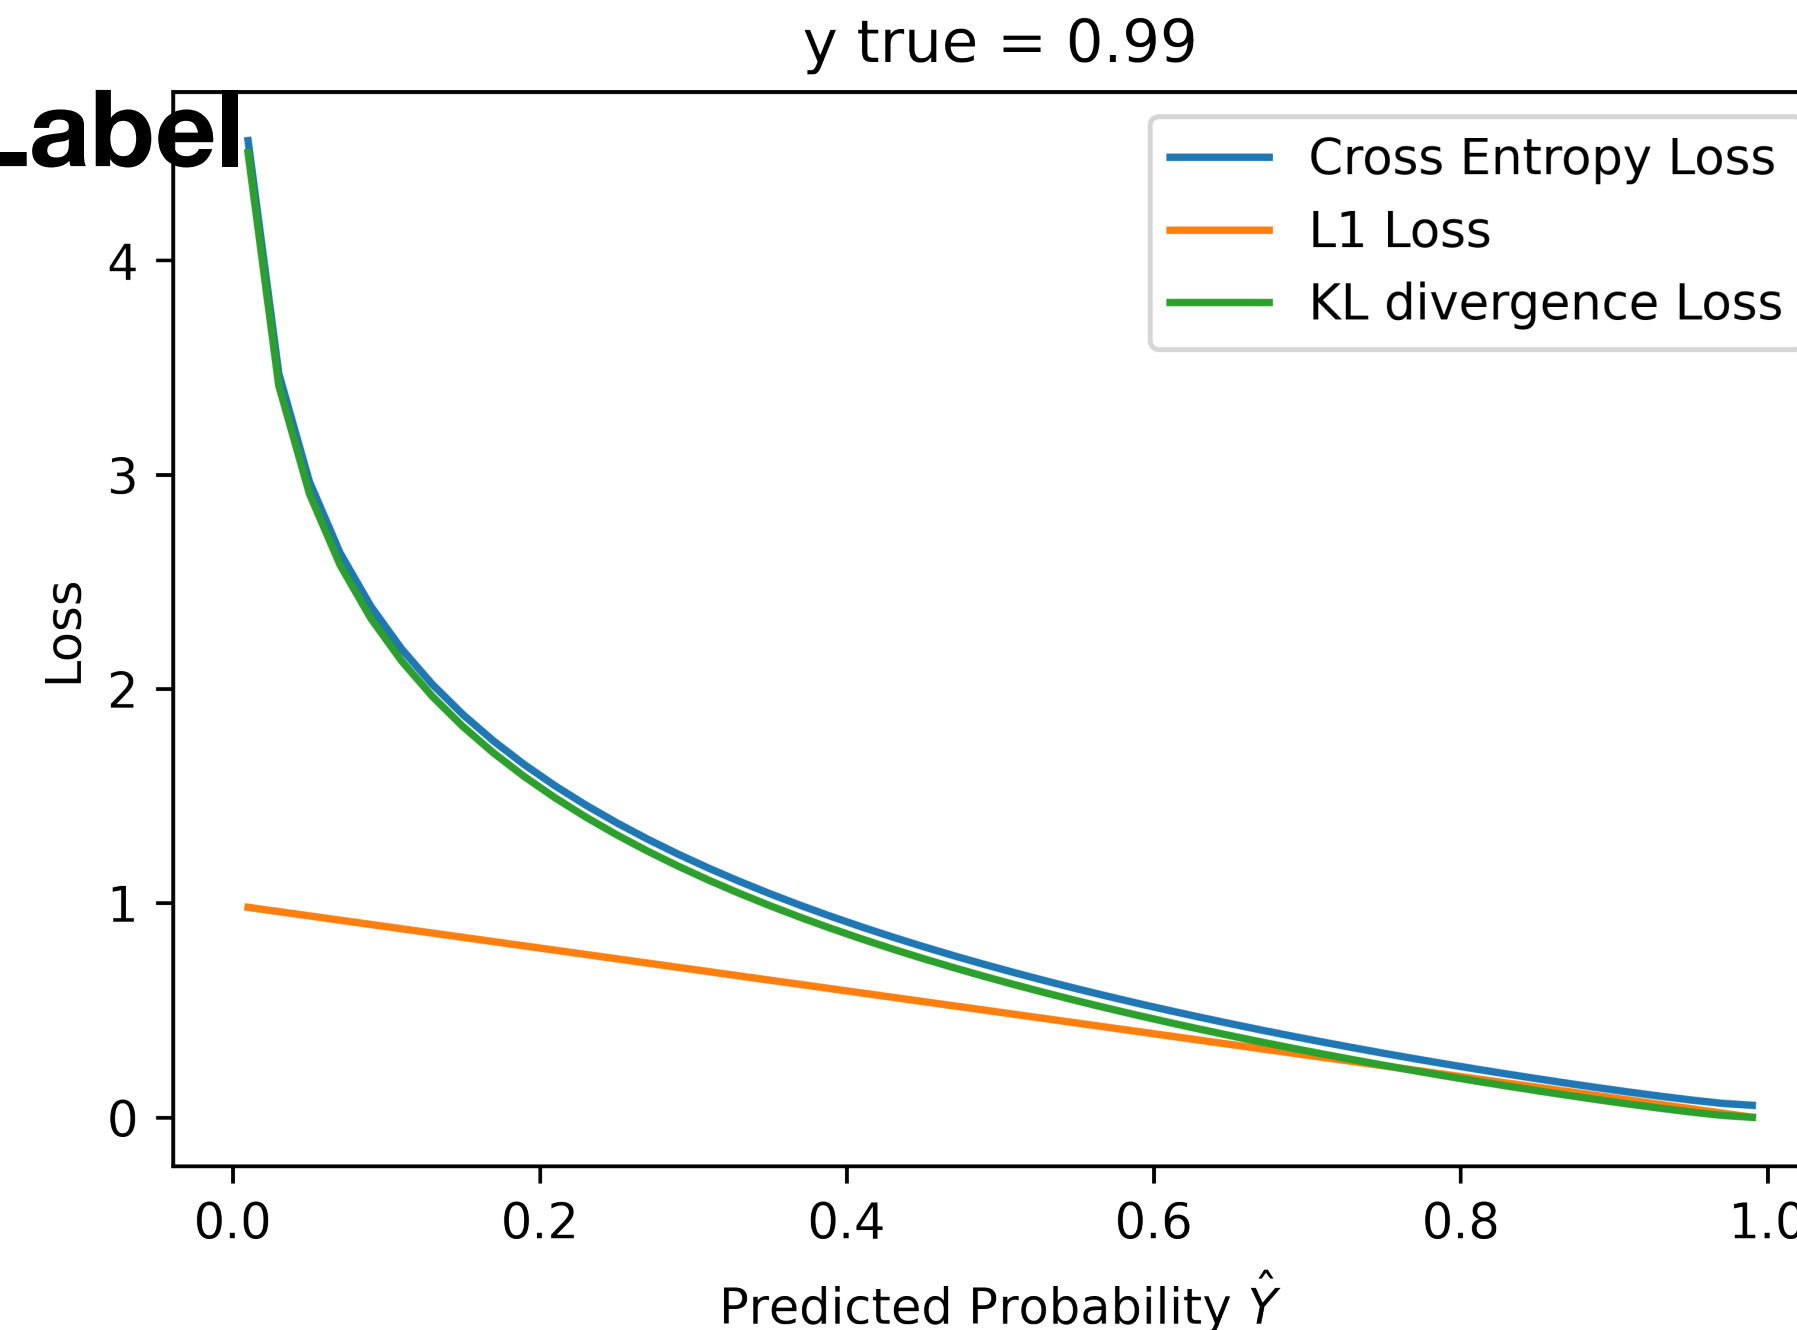

=

Negative Entropy


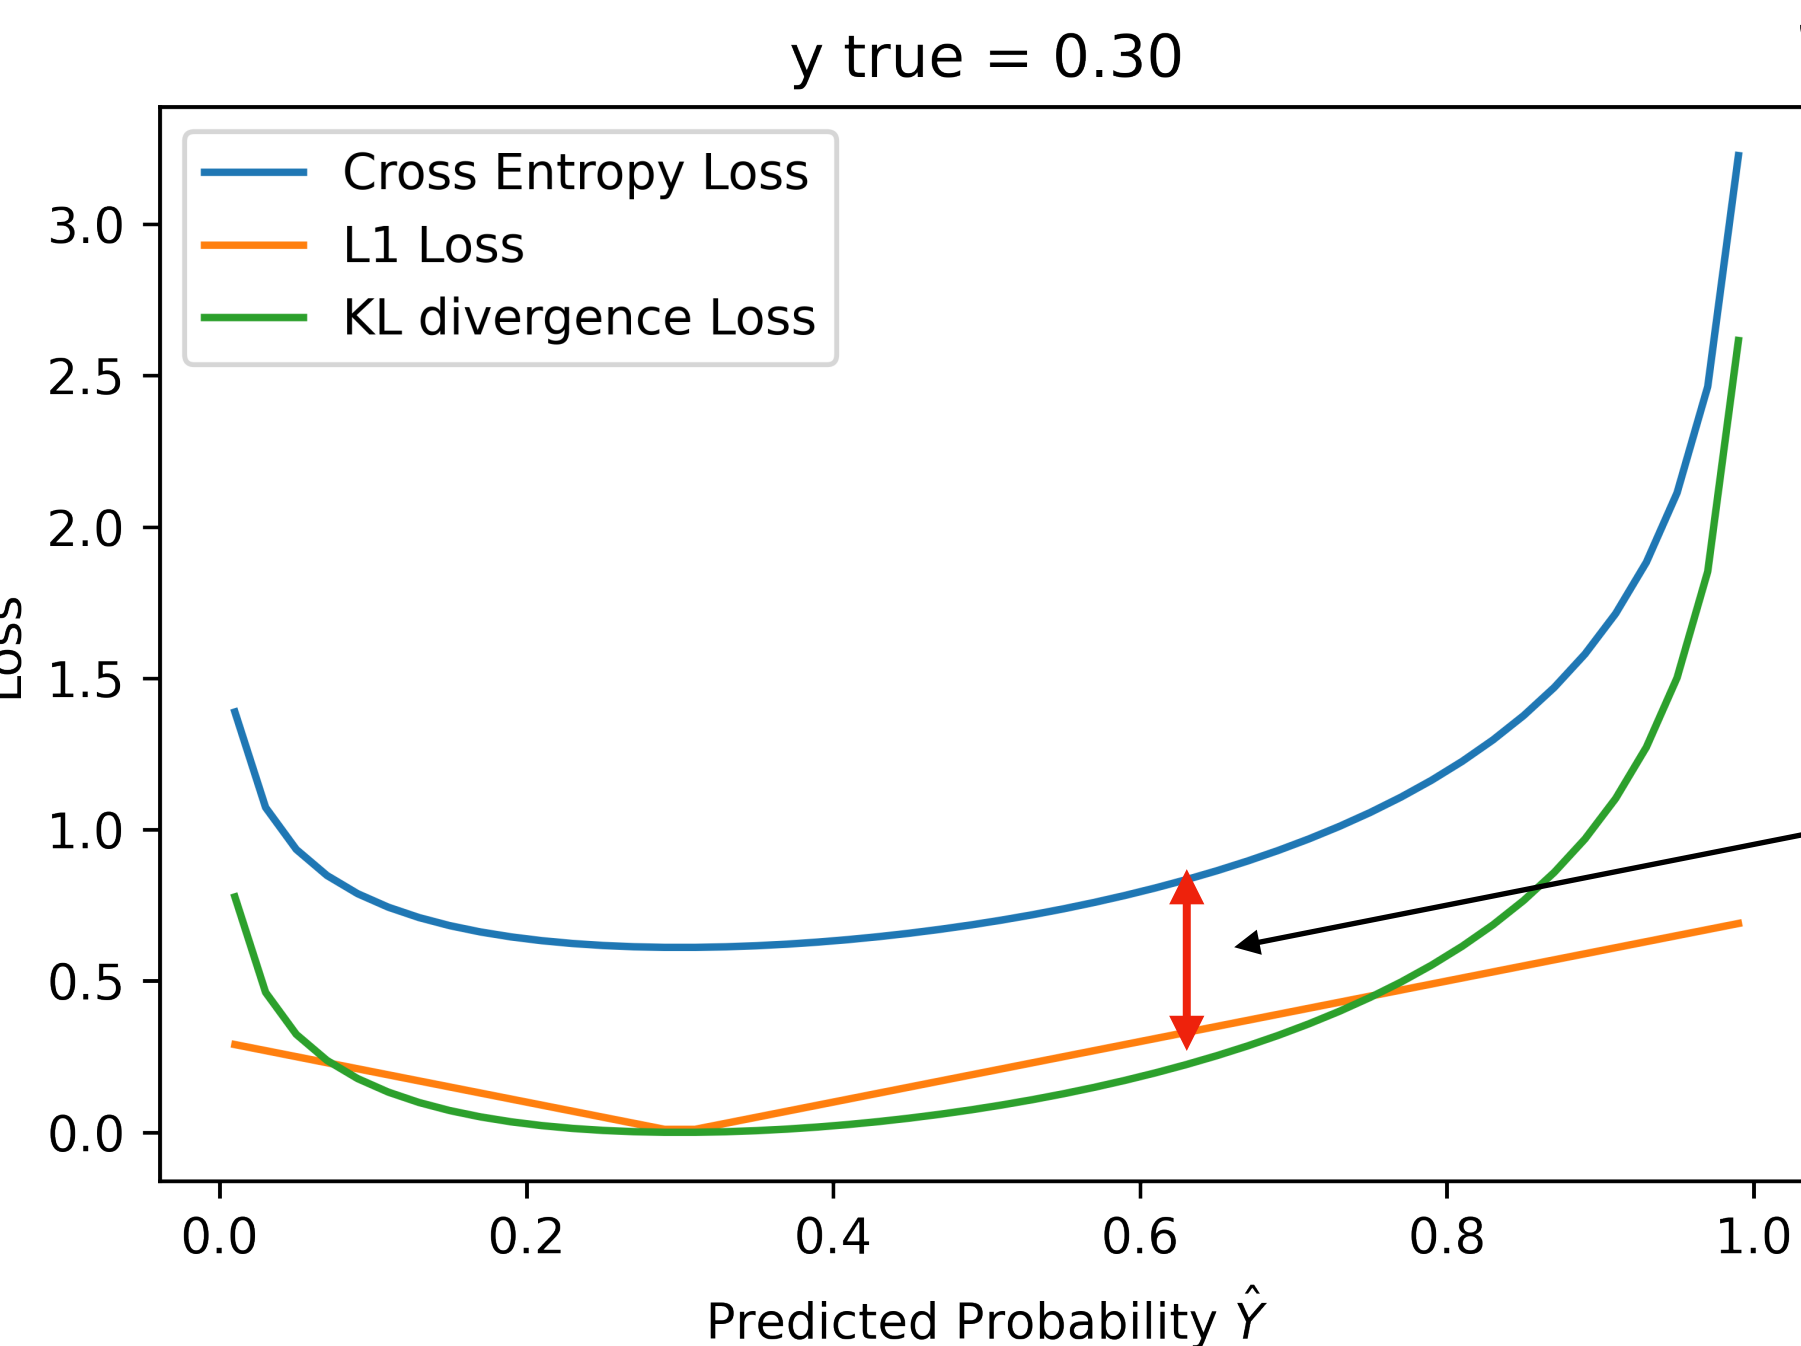
+

Cross Entropy Loss

Hard Label



Soft Label



Negative Entropy

$$= \sum_{c=1}^C Y_{i,c} \log Y_{i,c}$$



4-5. KL Divergence 2번째 해석

KL Divergence의 2번째 해석

- Kullback-Leibler Divergence Loss (KL Divergence)

$$\sum_{c=1}^C Y_{i,c} \cdot \log \left(\frac{Y_{i,c}}{\hat{Y}_{i,c}} \right) = \sum_{c=1}^C Y_{i,c} \log Y_{i,c} - Y_{i,c} \log \hat{Y}_{i,c}$$

Cross Entropy Term

Negative Entropy of $Y_{i,c}$

KL Divergence의 2번째 해석

- Kullback-Leibler Divergence Loss (KL Divergence)

$$\begin{aligned}\sum_{c=1}^C Y_{i,c} \cdot \log \left(\frac{Y_{i,c}}{\hat{Y}_{i,c}} \right) &= \sum_{c=1}^C Y_{i,c} \log Y_{i,c} - Y_{i,c} \log \hat{Y}_{i,c} \\ &= \sum_{c=1}^C Y_{i,c} \left(\log Y_{i,c} - \log \hat{Y}_{i,c} \right)\end{aligned}$$

KL Divergence의 2번째 해석

- Kullback-Leibler Divergence Loss (KL Divergence)

$$\sum_{c=1}^C Y_{i,c} \cdot \log \left(\frac{Y_{i,c}}{\hat{Y}_{i,c}} \right) = \sum_{c=1}^C Y_{i,c} \log Y_{i,c} - Y_{i,c} \log \hat{Y}_{i,c}$$

$$= \sum_{c=1}^C Y_{i,c} \left(\log Y_{i,c} - \log \hat{Y}_{i,c} \right)$$

$$\sum_i p_i f(p_i) = E_p[f]$$



KL Divergence의 2번째 해석

- Kullback-Leibler Divergence Loss (KL Divergence)

$$\begin{aligned}\sum_{c=1}^C Y_{i,c} \cdot \log \left(\frac{Y_{i,c}}{\hat{Y}_{i,c}} \right) &= Y_{i,c} \log(Y_{i,c}) - Y_{i,c} \log \hat{Y}_{i,c} \\ &= \sum_{c=1}^C Y_{i,c} \left(\log Y_{i,c} - \log \hat{Y}_{i,c} \right) \\ &= \mathbb{E}_{Y_{i,c}} \left[\log Y_{i,c} - \log \hat{Y}_{i,c} \right]\end{aligned}$$

확률 분포 $Y_{i,c}$ 에 대한 $\log Y_{i,c} - \log \hat{Y}_{i,c}$ 의 기댓값입니다.

(Expectation of log difference between $Y_{i,c}$ and $\hat{Y}_{i,c}$ with respect to $Y_{i,c}$ distribution)

KL Divergence의 2번째 해석

- **Kullback-Leibler Divergence Loss**

$$\sum_{c=1}^C Y_{i,c} \cdot \log \left(\frac{Y_{i,c}}{\hat{Y}_{i,c}} \right) = E_{Y_{i,c}} \left[\log Y_{i,c} - \log \hat{Y}_{i,c} \right]$$

- $\log(Y_{i,c})$ 와 $\log(\hat{Y}_{i,c})$ 간의 차이에 대한 $Y_{i,c}$ 분포의 기댓값.
- 즉, “ground truth label $Y_{i,c}$ 분포의 입장”에서 본 $\log(Y_{i,c})$ 와 $\log(\hat{Y}_{i,c})$ 간의 차이.



KL Divergence의 2번째 해석

- Kullback-Leibler Divergence Loss (KL Divergence)

$$\sum_{c=1}^C Y_{i,c} \cdot \log \left(\frac{Y_{i,c}}{\hat{Y}_{i,c}} \right) = E_{Y_{i,c}} \left[\log Y_{i,c} - \log \hat{Y}_{i,c} \right]$$

$$= E_{Y_{i,c}} \left[\log Y_{i,c} \right] - E_{Y_{i,c}} \left[\log \hat{Y}_{i,c} \right]$$

- KL Divergence은 확률 분포 $Y_{i,c}$ 에 대해서 $\log Y_{i,c}$ 의 기댓값과 $\log \hat{Y}_{i,c}$ 가 같아지도록 하는 것!

KL Divergence의 2번째 해석

- Kullback-Leibler Divergence Loss (KL Divergence)

$$\sum_{c=1}^C Y_{i,c} \cdot \log \left(\frac{Y_{i,c}}{\hat{Y}_{i,c}} \right) = E_{Y_{i,c}} \left[\log Y_{i,c} - \log \hat{Y}_{i,c} \right]$$

$$= E_{Y_{i,c}} \left[\log Y_{i,c} \right] - E_{Y_{i,c}} \left[\log \hat{Y}_{i,c} \right]$$

참고 사항: 

- KL Divergence가 0이 되는 것은 $Y = \hat{Y}$ 에 대한 필요 조건이지 충분 조건은 아니다.
- 기댓값이 일치하지만 분산 (Variance) 혹은 Higher order statistics이 같아지도록 강제 하지 않음.



4-6. Cross Entropy와 KL Divergence 에 대한 경사

Cross Entropy와 KL Divergence

- Kullback-Leibler Divergence Loss (KL Divergence)

$$L_{KL}(\hat{Y}_i, Y_i) = \sum_{c=1}^C Y_{i,c} \cdot \log \left(\frac{Y_{i,c}}{\hat{Y}_{i,c}} \right) = \sum_{c=1}^C \boxed{Y_{i,c} \log Y_{i,c}} - \boxed{Y_{i,c} \log \hat{Y}_{i,c}}$$

Negative Entropy of $Y_{i,c}$ Cross Entropy Term

Cross Entropy와 KL Divergence

- **Kullback-Leibler Divergence Loss (KL Divergence)**

$$L_{KL}(\hat{Y}_i, Y_i) = \sum_{c=1}^C Y_{i,c} \cdot \log \left(\frac{Y_{i,c}}{\hat{Y}_{i,c}} \right) = \sum_{c=1}^C \overbrace{Y_{i,c} \log Y_{i,c}}^{\text{Negative Entropy of } Y_{i,c}} \underbrace{- Y_{i,c} \log \hat{Y}_{i,c}}_{\text{Cross Entropy Term}}$$

- **Gradient Descent 핵심**

경사하강은 경사의 음의 방향으로 모델의 weight를 update 해주는 것.

$$W_{t+1} = W_t - \lambda \cdot \frac{dL}{dW}$$

Cross Entropy와 KL Divergence

- Kullback-Leibler Divergence Loss (KL Divergence)

$$L_{KL}(\hat{Y}_i, Y_i) = \sum_{c=1}^C Y_{i,c} \cdot \log \left(\frac{Y_{i,c}}{\hat{Y}_{i,c}} \right) = \sum_{c=1}^C Y_{i,c} \log Y_{i,c} - Y_{i,c} \log \hat{Y}_{i,c}$$

- Gradient Descent 핵심

경사하강은 경사의 음의 방향으로 모델의 weight를 update 해주는 것.

$$W_{t+1} = W_t - \lambda \cdot \frac{dL}{dW}$$



Cross Entropy와 KL Divergence

- KL Divergence Loss에 대한 경사

$$\begin{aligned} W_{t+1} &= W_t - \lambda \cdot \frac{dL_{KL}}{dW} \\ &= W_t - \lambda \cdot \sum_{c=1}^C \frac{d}{dW} \left(Y_{i,c} \log Y_{i,c} - Y_{i,c} \log \hat{Y}_{i,c} \right) \end{aligned}$$

$$Y_{i,c} \perp W, \hat{Y}_{i,c} \not\perp W$$

Cross Entropy와 KL Divergence

- KL Divergence Loss에 대한 경사

$$\begin{aligned}
 W_{t+1} &= W_t - \lambda \cdot \frac{dL_{KL}}{dW} \\
 &= W_t - \lambda \cdot \sum_{c=1}^C \frac{d}{dW} \left(\cancel{Y_{i,c} \log Y_{i,c}} - Y_{i,c} \log \hat{Y}_{i,c} \right) \quad \begin{matrix} \nearrow \\ =0 \end{matrix}
 \end{aligned}$$

$$Y_{i,c} \perp W, \hat{Y}_{i,c} \not\perp W$$

Cross Entropy와 KL Divergence

- KL Divergence Loss에 대한 경사

$$\begin{aligned}
 W_{t+1} &= W_t - \lambda \cdot \frac{dL_{KL}}{dW} \\
 &= W_t - \lambda \cdot \sum_{c=1}^C \frac{d}{dW} \left(\cancel{Y_{i,c} \log Y_{i,c}} - \boxed{Y_{i,c} \log \hat{Y}_{i,c}} \right)
 \end{aligned}$$

=0

Cross Entropy Term

$$Y_{i,c} \perp W, \hat{Y}_{i,c} \not\perp W$$

$$= W_t - \lambda \cdot \frac{dL_{CE}}{dW}$$

Cross Entropy와 KL Divergence

경사 하강 기반의 최적화:

KL Divergence Loss = Cross Entropy Loss



4. Section 4 요약

Section Summary

One Hot Encoding

- Categorical (범주형) 데이터를 처리하는데 사용되는 Encoding 방법
- 이것을 **One-hot-encoding**하면
 - “고양이”: [1, 0, 0]
 - “개”: [0, 1, 0]
 - “원숭이”: [0, 0, 1]
- 범주형 데이터를 **Vector로 변환**하는 기법!

Section Summary

Entropy

열역학 (Thermodynamics) 에서의 **Entropy**

물리 시스템의 **무질서한 정도**.


정보 이론 (Information Theory) 에서의 **Entropy**

확률 분포의 **불확실성**의 정도.

Cross Entropy Loss

Cross Entropy Loss (CE Loss)

$$\sum_{c=1}^C -Y_{i,c} \log \hat{Y}_{i,c}$$



$$-Y_{i,c=c'} \log(\hat{Y}_{i,c=c'})$$



$$-\log(\hat{Y}_{i,c=c'})$$

Ground Truth Label c' 일때,

$\hat{Y}_{i,c=c'}$ 가 높을수록 (잘 맞춘 것) CE Loss가 낮아짐.

$\hat{Y}_{i,c=c'}$ 가 낮을수록 (못 맞춘 것) CE Loss가 높아짐.

Section Summary

KL Divergence

- **Kullback-Leibler Divergence Loss (KL Divergence)**

$$\sum_{c=1}^C Y_{i,c} \cdot \log \left(\frac{Y_{i,c}}{\hat{Y}_{i,c}} \right) = \sum_{c=1}^C \underbrace{Y_{i,c} \log Y_{i,c}}_{\text{Negative Entropy of } Y_{i,c}} - \underbrace{Y_{i,c} \log \hat{Y}_{i,c}}_{\text{Cross Entropy Term}}$$

Negative Entropy

$$\sum_c Y_{i,c} \log Y_{i,c}$$

Cross Entropy Loss

$$\sum_{c=1}^C -Y_{i,c} \log \hat{Y}_{i,c}$$

Section Summary

KL Divergence

- **Kullback-Leibler Divergence Loss (KL Divergence)**

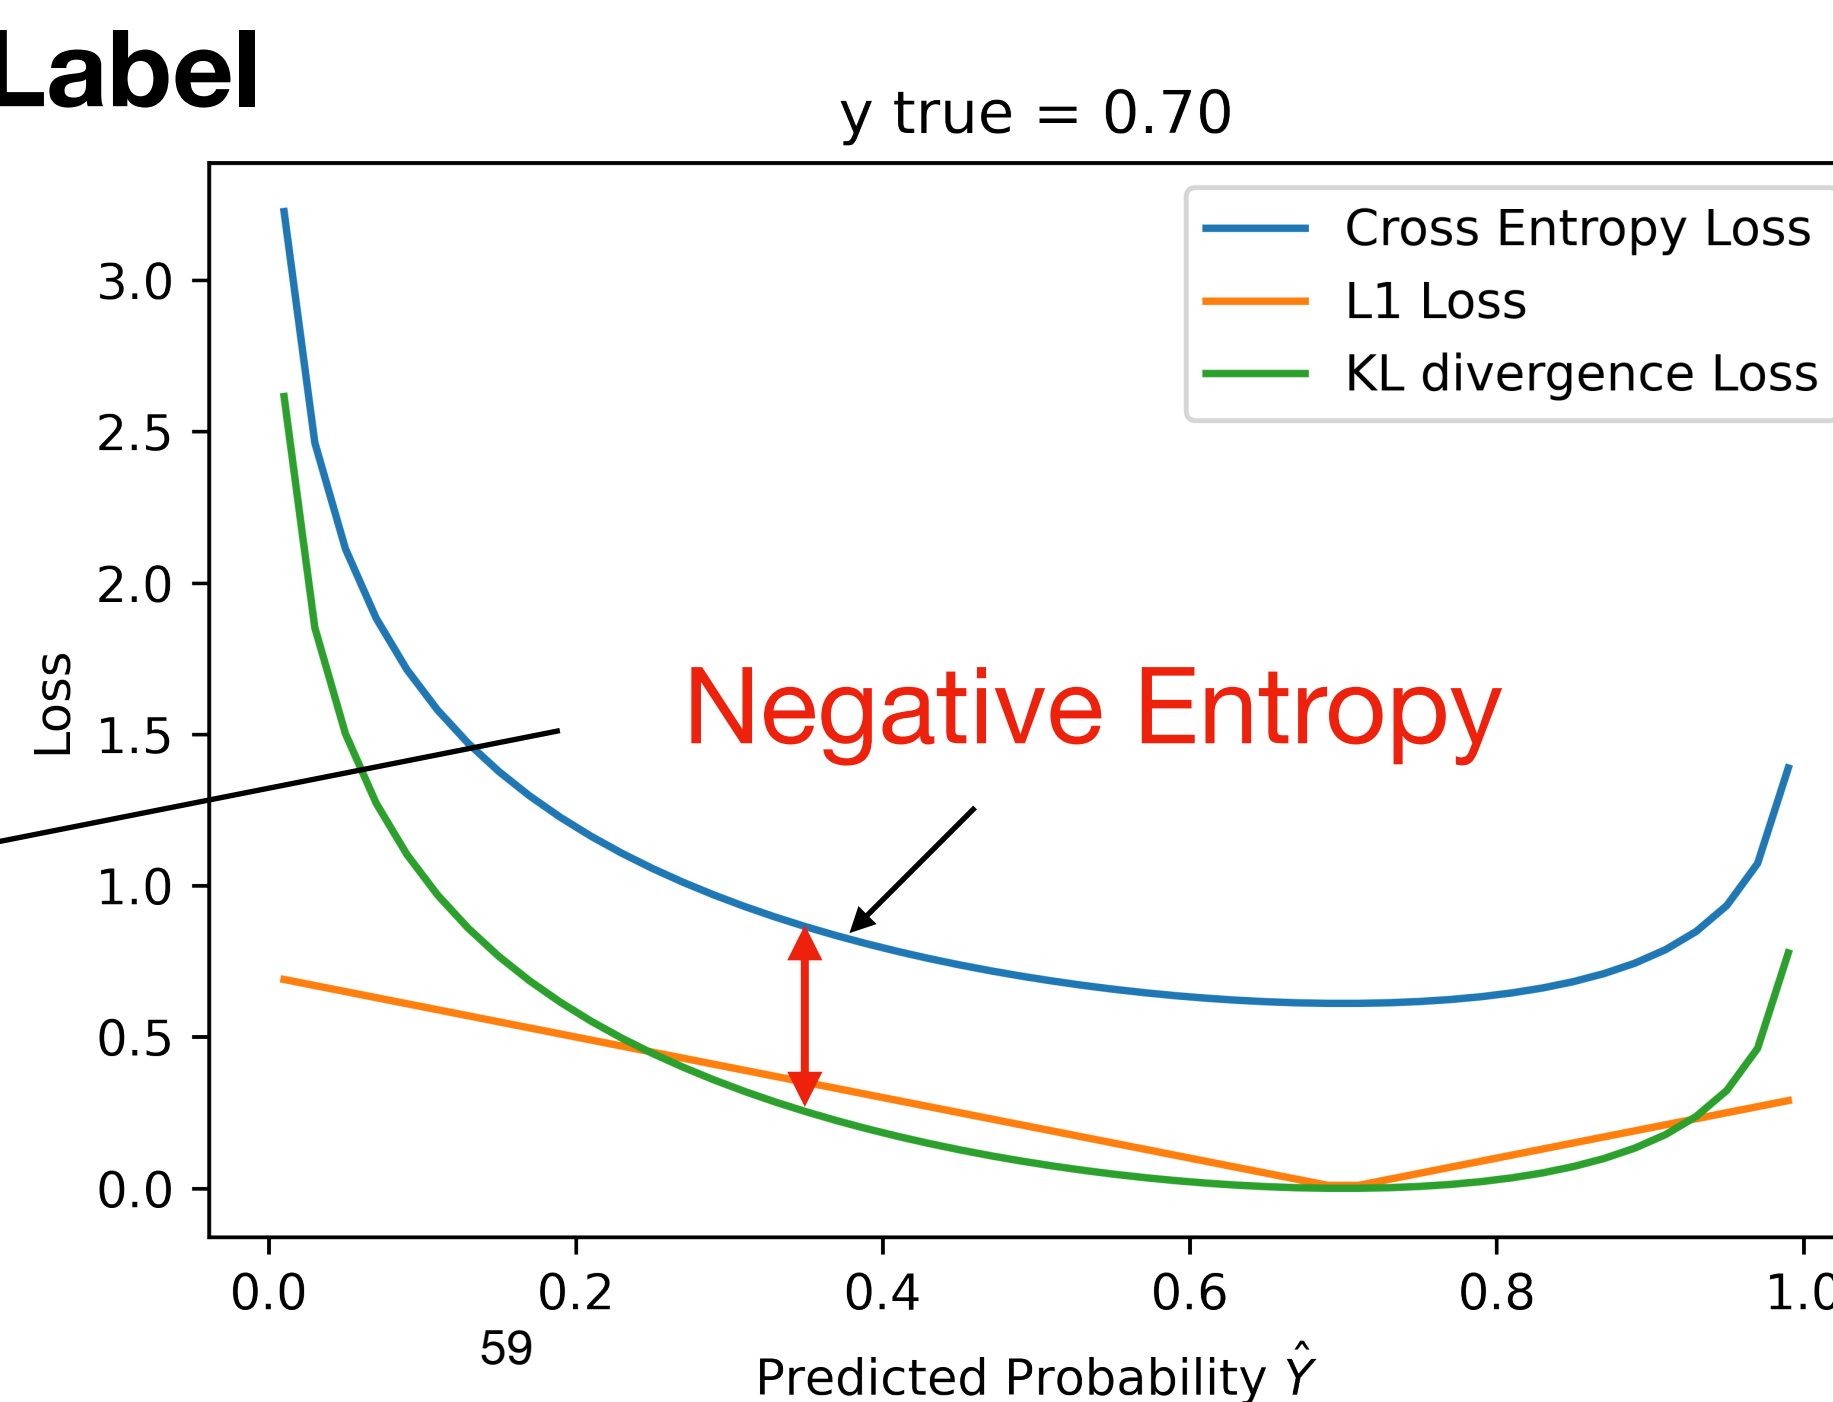


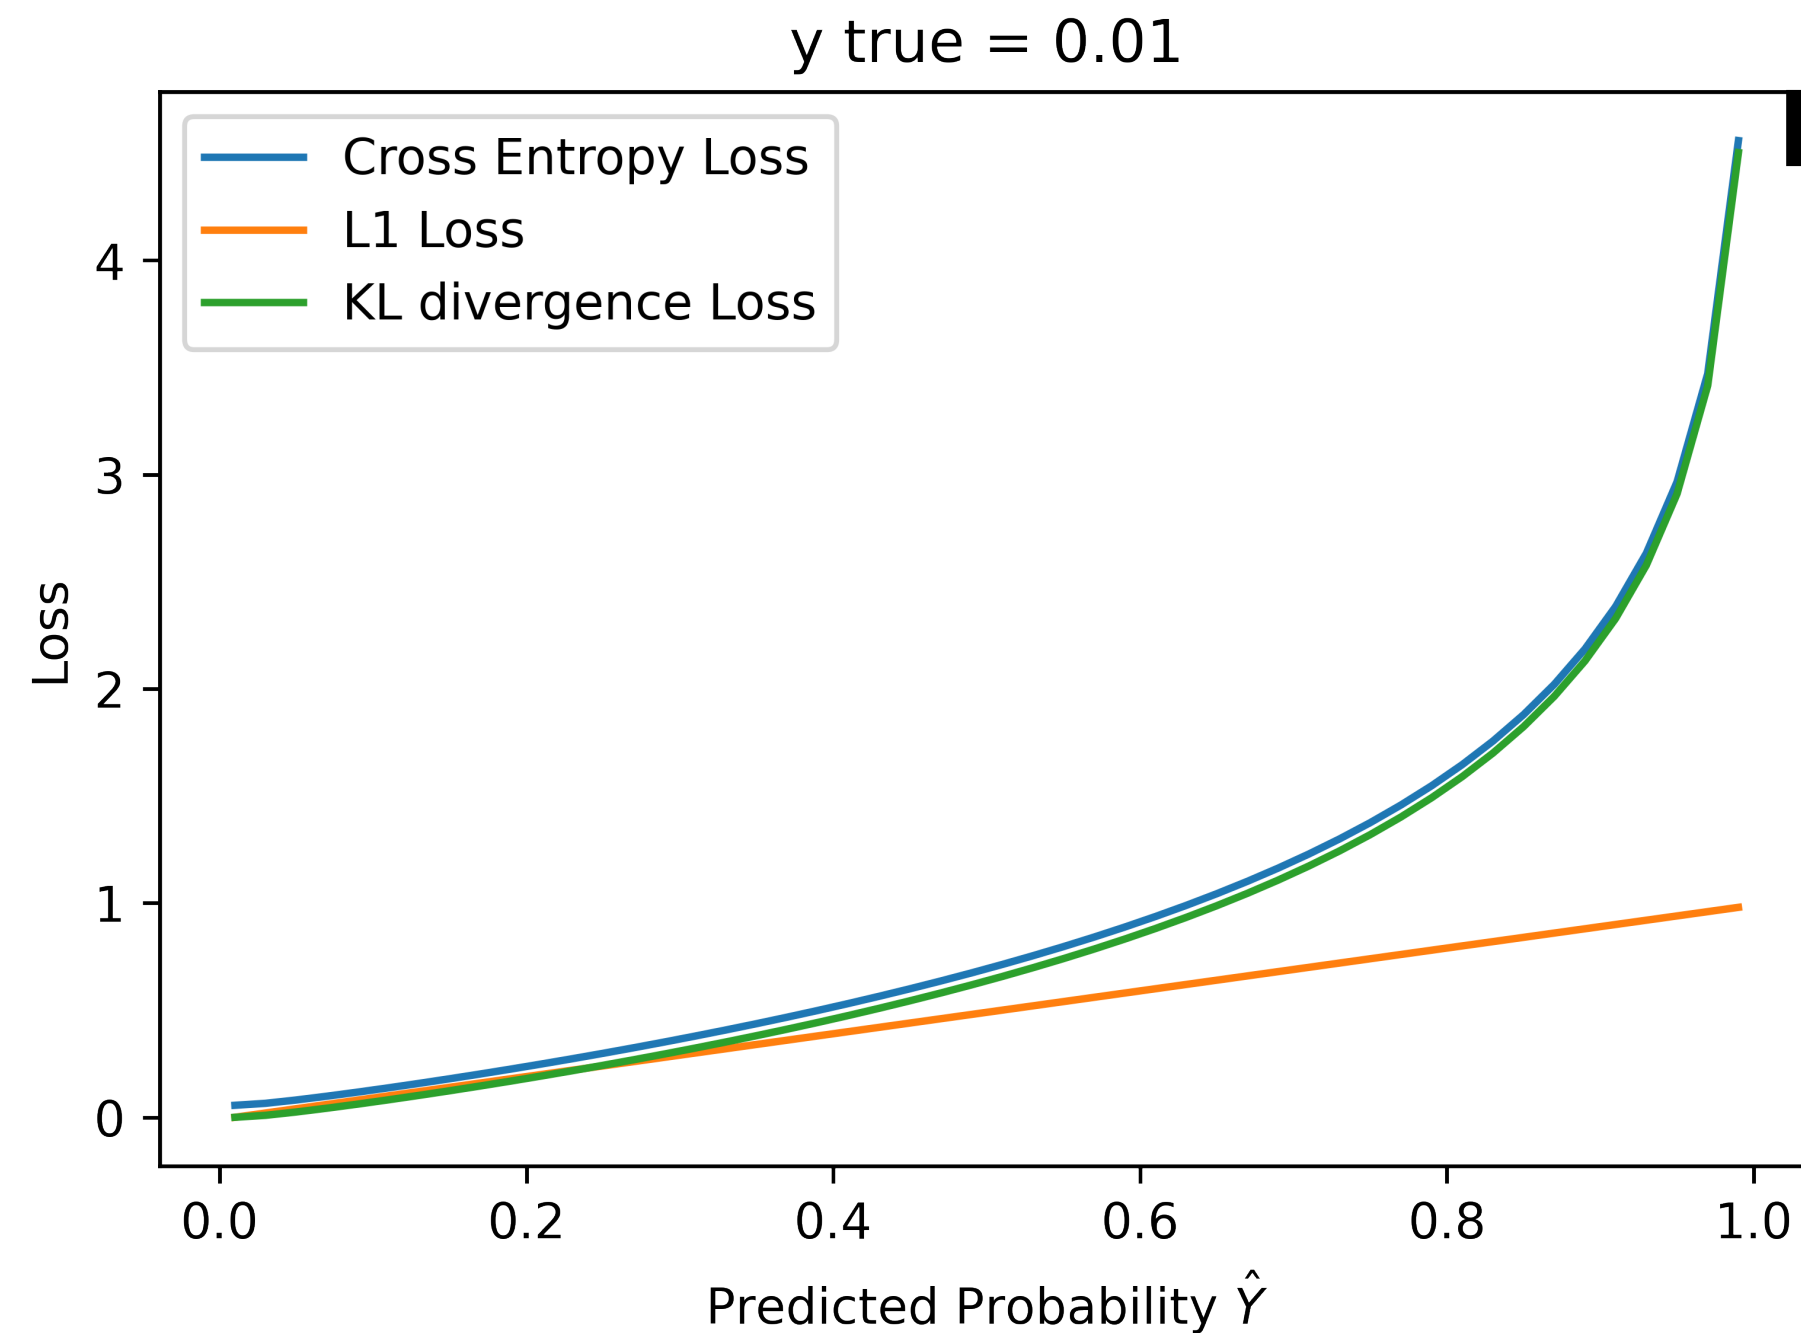
확률 분포 $Y_{i,c}$ 에 대한 $\log Y_{i,c} - \log \hat{Y}_{i,c}$ 의 기댓값.

(Expectation of log difference between $Y_{i,c}$ and $\hat{Y}_{i,c}$ with respect to $Y_{i,c}$ distribution)

$$\sum_{c=1}^C Y_{i,c} \cdot \log \left(\frac{Y_{i,c}}{\hat{Y}_{i,c}} \right) = E_{Y_{i,c}} \left[\log Y_{i,c} - \log \hat{Y}_{i,c} \right]$$

확률 분포 $Y_{i,c}$ 에 대해서 $\log Y_{i,c}$ 의 기댓값과 $\log \hat{Y}_{i,c}$ 의 기댓값의 차이

$$= E_{Y_{i,c}} \left[\log Y_{i,c} \right] - E_{Y_{i,c}} \left[\log \hat{Y}_{i,c} \right]$$



Negative Entropy

$$= \sum_{c=1}^C Y_{i,c} \log Y_{i,c}$$

Section Summary

- KL Divergence Loss에 대한 경사

$$\begin{aligned}
 W_{t+1} &= W_t - \lambda \cdot \frac{dL_{KL}}{dW} \\
 &= W_t - \lambda \cdot \sum_{c=1}^C \frac{d}{dW} \left(\cancel{Y_{i,c} \log Y_{i,c}} - \boxed{Y_{i,c} \log \hat{Y}_{i,c}} \right)
 \end{aligned}$$

=0

Cross Entropy Term

$$Y_{i,c} \perp W, \hat{Y}_{i,c} \not\perp W$$

$$= W_t - \lambda \cdot \frac{dL_{CE}}{dW}$$

Next Up!

Next Up

What is Deep Learning?

- Neural Network가 학습되는 과정 = weight값이 최적화되는 과정

Gradient Descent (경사 하강)을 통한 **Loss function (손실 함수)** 값을 최소화하도록

weight 값을 최적화하여 점진적으로 모델의 예측 정확도를 높인다.

섹션 3. 손실 함수 (Loss Function)

섹션 5. 경사 하강법 (Gradient Descent)

Next Up

What is Deep Learning?



- Neural Network가 학습되는 과정 = weight값이 최적화되는 과정

섹션 3. 손실 함수 (Loss Function)

Gradient Descent (경사 하강)을 통한 **Loss function (손실 함수)** 값을 최소화하도록

weight 값을 최적화하여 점진적으로 모델의 예측 정확도를 높인다.

섹션 5. 경사 하강법 (Gradient Descent)

Loss Function을 최소화하는 방법인 **Gradient Descent**에 대해서 배워보겠습니다!